

Implementasi Pipeline Big Data Berbasis ETL dan ELT untuk Analisis Keterlambatan Penerbangan

Anom Nur Maulid

Program Studi S1 Teknik Komputer

Universitas Telkom

Bandung, Indonesia

anompetir@student.telkomuniversity.ac.id

Muhammad Rayhan Ananta

Kabalmay

Program Studi S1 Teknik Komputer

Universitas Telkom

Bandung, Indonesia

rayhanananta@student.telkomuniversity.ac.id

Angel Metanosa

Dosen Big Data

Universitas Telkom

Bandung, Indonesia

Abstrak—Makalah ini menyajikan perancangan, implementasi, dan evaluasi komparatif pipeline big data berbasis Extract, Transform, Load (ETL) dan Extract, Load, Transform (ELT) yang diterapkan pada analisis keterlambatan penerbangan domestik Amerika Serikat periode 2019 hingga 2023. Kedua pipeline memproses sampel 150.000 rekaman penerbangan dari dataset 3 juta baris yang diperoleh dari Biro Statistik Transportasi AS (BTS). Pipeline ETL melakukan pembersihan data, normalisasi, rekayasa fitur, dan pembangunan star schema di Google Colab menggunakan pemrosesan GPU-accelerated cuDF/RAPIDS sebelum memuat hasilnya ke Google BigQuery. Pipeline ELT memuat data mentah ke BigQuery terlebih dahulu, kemudian mengeksekusi seluruh langkah transformasi dan agregasi menggunakan BigQuery SQL. Enam dimensi kualitas data divalidasi pada kedua pipeline, masing-masing mencapai tingkat referential integrity 99,9% dan lulus lima dari enam aturan validasi. Temuan utama menunjukkan tingkat ketepatan waktu (on-time rate) sebesar 66,04%, rata-rata keterlambatan keberangkatan 10,09 menit, serta peningkatan signifikan rata-rata keterlambatan dari 1,71 menit pada tahun 2020 menjadi 14,50 menit pada tahun 2023 seiring pemulihan permintaan pasca-pandemi. Dashboard Looker Studio empat halaman yang interaktif menyediakan akses analitik terhadap metrik KPI, tren keterlambatan, perbandingan maskapai, dan analisis tingkat rute. Hasil penelitian menunjukkan bahwa ELT lebih unggul dalam fleksibilitas transformasi untuk beban kerja analitik iteratif, sementara ETL memberikan tata kelola skema yang lebih kuat untuk pelaporan terstruktur.

Kata Kunci—big data, pipeline ETL, pipeline ELT, analitik keterlambatan penerbangan, Google BigQuery, cuDF, RAPIDS, komputasi GPU, Looker Studio, data warehouse

I. PENDAHULUAN

Industri penerbangan menghasilkan volume data operasional yang sangat besar setiap harinya. Di Amerika Serikat, Biro Statistik Transportasi (BTS) mencatat jutaan operasi penerbangan domestik setiap tahun, meliputi waktu keberangkatan dan kedatangan, penyebab keterlambatan, kode pembatalan, serta jarak rute penerbangan. Mengubah data mentah tersebut menjadi wawasan yang dapat ditindaklanjuti memerlukan pipeline rekayasa data yang andal dan mampu menangani volume, variasi, serta kecepatan data dalam skala besar.

Dua paradigma utama yang digunakan untuk membangun pipeline semacam ini adalah Extract,

Transform, Load (ETL) dan Extract, Load, Transform (ELT). Pada paradigma ETL, data dibersihkan dan distrukturkan sebelum masuk ke data warehouse sehingga warehouse menjadi penyimpanan data yang telah dikurasi dan siap dianalisis. Pada paradigma ELT, data mentah dimuat ke warehouse atau data lake terlebih dahulu, dan transformasi dilakukan pada tahap kueri menggunakan mesin komputasi SQL native milik warehouse. Kemunculan cloud data warehouse seperti Google BigQuery, Amazon Redshift, dan Snowflake telah membuat ELT semakin praktis karena platform-platform ini mampu mengeksekusi transformasi SQL yang kompleks dalam skala besar tanpa memerlukan lapisan komputasi terpisah.

Makalah ini mengimplementasikan kedua paradigma pada dataset yang sama dan membandingkan hasil kualitas data, trade-off desain skema, serta kapabilitas analitisnya. Dataset utama berupa sampel 150.000 baris dari dataset 3 juta baris Flight Delay and Cancellation Dataset (2019–2023) yang diterbitkan oleh Departemen Transportasi AS melalui Kaggle [1], diperkaya dengan Global Airports Dataset [2] yang menyediakan informasi geografis dan zona waktu bandara. Pemrosesan berbasis GPU menggunakan NVIDIA cuDF/RAPIDS [3] di Google Colab secara signifikan mengurangi waktu ekstraksi dan transformasi dibandingkan pemrosesan berbasis CPU saja.

Makalah ini disusun sebagai berikut. Bagian II mengulas penelitian terkait tentang arsitektur pipeline big data. Bagian III mendeskripsikan dataset, desain sistem, dan metodologi kedua pipeline. Bagian IV menyajikan hasil dan analisis komparatif. Bagian V menyimpulkan temuan utama dan arah penelitian selanjutnya.

II. TINJAUAN PUSTAKA

Paradigma ETL telah menjadi fondasi data warehousing enterprise selama beberapa dekade [4]. Alat ETL tradisional seperti Apache Spark, Talend, dan Informatica menyediakan logika transformasi terstruktur yang memastikan kepatuhan skema sebelum data memasuki warehouse. Prinsip pemodelan dimensional Kimball [5], yang mendasari star schema yang digunakan pada pipeline ETL dalam penelitian ini, tetap diadopsi secara luas dalam

konteks business intelligence karena menyederhanakan pola kueri analitis.

Kemunculan cloud data warehouse native telah mengalihkan minat ke arah arsitektur ELT. Stitch, Fivetran, dan dbt (data build tool) merepresentasikan generasi tooling berorientasi ELT yang memisahkan ingesti dari transformasi dan memungkinkan logika transformasi SQL yang dikontrol versi berjalan sepenuhnya di dalam warehouse [6]. Arsitektur serverless Google BigQuery sangat sesuai dengan model ini karena ditagihkan per byte yang dipindai, bukan untuk sumber daya komputasi persisten, sehingga transformasi SQL iteratif menjadi layak secara ekonomis.

Pemrosesan dataframe dengan akselerasi GPU telah banyak dieksplorasi dalam komputasi ilmiah, namun penerapannya pada pipeline rekayasa data masih relatif baru. Library cuDF dari RAPIDS [3] menyediakan API yang kompatibel dengan pandas dan dieksekusi pada GPU NVIDIA, mengurangi waktu parsing CSV dan transformasi in-memory secara signifikan dibandingkan pandas berbasis CPU untuk dataset berukuran ratusan megabyte. Percepatan GPU hingga 10–50 kali untuk operasi DataFrame standar pada dataset di atas 100 MB telah dilaporkan dalam beberapa penelitian terdahulu [7].

Prediksi dan analitik keterlambatan penerbangan telah banyak diteliti menggunakan pendekatan machine learning [8, 9]. Namun, sedikit penelitian yang berfokus pada pipeline rekayasa data itu sendiri sebagai kontribusi utama. Makalah ini mengatasi kesenjangan tersebut dengan menyediakan perbandingan implementasi dan validasi antara pendekatan ETL dan ELT pada dataset penerbangan nyata, mencakup desain skema, validasi kualitas data enam dimensi, dan integrasi dashboard interaktif.

III. METODOLOGI

A. Dataset

Dua dataset publik dari Kaggle digunakan dalam penelitian ini:

(1) **Flight Delay and Cancellation Dataset (2019–2023)** [1]: Diterbitkan oleh BTS AS, dataset ini memuat sekitar 3 juta rekaman penerbangan domestik (± 585 MB). Setiap rekaman terdiri dari 32 atribut yang mencakup kode maskapai, bandara asal dan tujuan, waktu keberangkatan dan kedatangan terjadwal dan aktual, menit keterlambatan per penyebab, kode pembatalan, serta jarak penerbangan. Sampel sebanyak 150.000 baris digunakan untuk seluruh eksperimen pipeline.

(2) **Global Airports Dataset (IATA, ICAO, Timezone)** [2]: Tabel referensi berisi 6.393 baris yang menyediakan nama bandara, kode IATA dan ICAO, kota, negara, lintang, bujur, serta string zona waktu IANA untuk bandara di seluruh dunia.

Dataset penerbangan memiliki missing values pada beberapa kolom yang berkorelasi dengan penerbangan yang dibatalkan (DEP_TIME: 3.893 null; DEP_DELAY: 3.896 null; kolom TAXI: ± 3.937 null). Wawasan kritis yang menjadi panduan kedua pipeline adalah bahwa nilai null pada delay keberangkatan untuk penerbangan yang dibatalkan tidak boleh diimputasi dengan nol atau nilai median, karena hal tersebut secara artifisial meningkatkan on-time rate dan mendistorsi statistik distribusi keterlambatan.

B. Arsitektur Pipeline ETL

Pipeline ETL diimplementasikan dalam notebook Google Colab menggunakan Python dengan cuDF 26.02 (RAPIDS) untuk pemrosesan GPU-accelerated pada Tesla T4 GPU (15.360 MiB VRAM). Pipeline terdiri dari empat fase:

Ekstrak: CSV penerbangan (585 MB) dibaca menggunakan `cuDF.read_csv()` dengan batas 150.000 baris, mengurangi waktu baca menjadi 5,86 detik dibandingkan pandas CPU yang membutuhkan waktu jauh lebih lama. File airports (0,65 MB) dibaca secara penuh. Kedua file disimpan ke Google Drive sebagai CSV mentah.

Transform — Pembersihan Data: Tiga belas baris duplikat dihapus berdasarkan composite key lima kolom (FL_DATE, AIRLINE, ORIGIN, DEST, DEP_TIME). Nilai null pada DEP_DELAY dan ARR_DELAY diimputasi dengan nilai median kolom hanya untuk penerbangan yang tidak dibatalkan; penerbangan yang dibatalkan mempertahankan nilai NULL guna menghindari bias distribusi. Hard-cap outlier menghapus penerbangan dengan DEP_DELAY di luar rentang $[-120, 1440]$ menit (9 baris dihapus), menggantikan metode berbasis IQR yang secara keliru menandai keberangkatan tepat waktu sebagai outlier.

Transform — Standarisasi dan Rekayasa Fitur: MinMaxScaler dari scikit-learn menormalisasi DEP_DELAY dan ARR_DELAY ke rentang $[0, 1]$ pada baris non-cancelled. Lima fitur baru diturunkan: FLIGHT_YEAR, FLIGHT_MONTH, DAY_OF_WEEK, DELAY_STATUS (kategorikal: on_time / minor_delay / moderate_delay / severe_delay / cancelled), dan IS_WEEKEND. Tabel dimensi bandara digabungkan dua kali (untuk origin dan destination) menggunakan left join untuk menghindari kehilangan penerbangan yang kode bandaranya tidak tersedia dalam tabel referensi global.

Muat — Star Schema: Pipeline membangun star schema di dataset BigQuery `etl_flight_analytics` yang terdiri dari empat tabel: `fact_flights` (149.801 baris, 20 kolom), `dim_airline` (18 baris), `dim_airport` (6.372 baris), dan `dim_date` (1.704 baris). Tabel denormalisasi tambahan (`etl_transformed`, 149.978 baris, 50 kolom) dihasilkan untuk

penggunaan langsung oleh Looker Studio. Proses upload menggunakan pandas-gbq dengan opsi `if_exists='replace'`.

C. Arsitektur Pipeline ELT

Pipeline ELT mengikuti langkah ekstraksi yang sama, namun berbeda dengan memuat data mentah yang tidak dimodifikasi ke BigQuery terlebih dahulu. Seluruh transformasi kemudian dilakukan di dalam BigQuery menggunakan SQL:

Ekstrak: `cuDF` membaca 150.000 baris penerbangan dan 6.393 baris bandara masing-masing dalam 4,54 detik dan 1,69 detik. Nama kolom hanya di-lowercase (satu-satunya modifikasi pra-muat). File disimpan ke direktori /datalake di Google Drive.

Muat (data mentah ke BigQuery): `raw_flights` (150.000 baris, 32 kolom) dan `raw_airports` (6.393 baris, 13 kolom) dimuat ke dataset BigQuery `elt_flight_analytics` dalam 12,47 detik tanpa transformasi data apapun. Ini merupakan lapisan data lake dalam arsitektur ELT.

Transform — Pembersihan via SQL: Pernyataan `CREATE OR REPLACE TABLE AS SELECT` (CTAS) membuat tabel `elt_cleaned_flights` menggunakan `ROW_NUMBER()` `OVER PARTITION BY` untuk deduplikasi, `PARSE_DATE()` untuk casting tipe data, dan logika `CASE WHEN` untuk mempertahankan nilai NULL pada delay keberangkatan penerbangan yang dibatalkan. Klausula `WHERE` hard-cap memfilter `dep_delay BETWEEN -120 AND 1440` untuk baris non-cancelled. Hasilnya adalah 148.843 baris dalam 10 kolom.

Transform — Penggabungan dan Rekayasa Fitur via SQL: Pernyataan CTAS kedua menggabungkan `elt_cleaned_flights` dengan `elt_cleaned_airports` menggunakan `LEFT JOIN` pada kode IATA untuk bandara asal dan tujuan, kemudian menambahkan enam kolom turunan: `FLIGHT_YEAR`, `FLIGHT_MONTH`, `DAY_OF_WEEK`, `DELAY_STATUS`, `IS_WEEKEND`, dan `QUARTER`. Tabel `elt_transformed` yang dihasilkan berisi 148.843 baris dan 26 kolom.

Transform — Agregasi via SQL: CTAS terakhir membuat tabel `elt_metrics` (1.492 baris, 11 kolom) dengan mengelompokkan data berdasarkan maskapai, tahun, bulan, dan negara asal, serta menghitung rata-rata delay yang mengecualikan penerbangan dibatalkan dan on-time rate menggunakan formula `COUNTIF(on_time) / NULLIF(COUNTIF(cancelled=0), 0)`.

D. Validasi Kualitas Data

Kedua pipeline dievaluasi terhadap enam dimensi kualitas data, divalidasi secara independen setelah fase transformasi. Kriteria dan hasil validasi ditampilkan pada Tabel I.

TABEL I

Hasil Validasi Kualitas Data

Dimensi	ETL	ELT	Metode
1. Keunikan Data	LULUS	LULUS	Deduplikasi composite key
2. Pemeriksaan Null	LULUS	LULUS	Kolom kritis NOT NULL
3. Pemeriksaan Rentang	LULUS	LULUS	BETWEEN -120 AND 1440
4. Konsistensi Tipe Data	LULUS	LULUS	datetime / tipe DATE
5. Integritas Referensial	-	-	99,9% cocok (177/176 baris)
6. Pemeriksaan Distribusi	LULUS	LULUS	mean=10,09 mnt, std=48,54

IV. HASIL DAN PEMBAHASAN

A. Performa Pipeline

Tabel II merangkum jumlah rekaman di kedua pipeline dari tahap ekstraksi hingga output akhir. Selisih 0,08% jumlah rekaman antara ETL (149.801 pada `fact_flights`) dan ELT (148.843 pada `elt_transformed`) disebabkan oleh strategi deduplikasi yang berbeda: ETL mendeduplikasi menggunakan composite key lima kolom termasuk `DEP_TIME`, sementara ELT menggunakan window function dengan empat kolom partisi. Kedua nilai masih dalam rentang yang dapat diterima, dan peringatan integritas referensial (176–177 baris dengan kode IATA yang tidak cocok) bersifat non-kritis karena bandara tersebut merupakan kasus tepi yang tidak terdapat dalam referensi global.

TABEL II

Jumlah Rekaman per Tahap Pipeline

Tahap	ETL	ELT
Ekstraksi mentah	150.000	150.000
Setelah pembersihan	149.978	148.843
Tabel akhir (siap analisis)	149.801	148.843
Metrik teragregasi	-	1.492

B. Indikator Kinerja Utama (KPI)

Secara agregat selama periode 2019–2023, dataset menghasilkan statistik sebagaimana ditampilkan pada Tabel III.

TABEL III

Ringkasan KPI Keseluruhan 2019–2023

Indikator	Nilai
Total penerbangan yang dianalisis	148.843-149.978
Rata-rata keterlambatan keberangkatan	10,09 menit
Rata-rata keterlambatan kedatangan	4,22 menit
Tingkat ketepatan waktu (on-time rate)	66,04%
Total pembatalan	3.898
Rata-rata jarak penerbangan	809,14 mil

C. Analisis Tren Temporal

Tren tahunan mengungkap dampak signifikan pandemi COVID-19 terhadap penerbangan domestik AS. Pada tahun 2020, volume penerbangan turun menjadi 23.712 (penurunan 36% dari 37.455 pada 2019), sementara total pembatalan melonjak ke angka 1.441. Menariknya, rata-rata keterlambatan keberangkatan justru turun drastis ke 1,71 menit pada 2020, nilai terendah sepanjang periode studi, mencerminkan berkurangnya kepadatan lalu lintas udara seiring runtuhnya permintaan perjalanan.

Pemulihan pascapandemi memperkenalkan tekanan operasional baru yang berkelanjutan. Rata-rata keterlambatan meningkat setiap tahunnya: 9,49 menit pada 2021, 12,45 menit pada 2022, dan 14,50 menit pada 2023. Trajektori ini mengindikasikan bahwa meskipun volume penerbangan kembali mendekati level prapandemi (2022: 34.293; 2023: 23.178 untuk tahun parsial yang diambil sampelnya), ketersediaan kru, simpanan pekerjaan pemeliharaan, dan kapasitas bandara belum pulih dengan laju yang sebanding.

D. Analisis Tingkat Maskapai

Di antara 18 maskapai dalam dataset, JetBlue Airways menunjukkan rata-rata keterlambatan keberangkatan tertinggi sebesar 18,71 menit meskipun hanya mengoperasikan 5.514 penerbangan dalam sampel. Frontier Airlines Inc. (15,19 menit) dan Allegiant Air (13,85 menit) menempati posisi kedua dan ketiga. Southwest Airlines Co., maskapai dengan volume penerbangan tertinggi sebesar 28.190 penerbangan, mempertahankan rata-rata keterlambatan moderat sebesar 10,85 menit. Delta Air Lines Inc. mencapai keseimbangan terbaik antara volume dan ketepatan waktu di antara maskapai besar, dengan 19.794 penerbangan dan rata-rata keterlambatan 8,04 menit.

Kategorisasi status delay menunjukkan bahwa 66% penerbangan tepat waktu, 10,5% mengalami keterlambatan ringan (1–15 menit), 11,4% keterlambatan sedang (16–60 menit), dan 6,1% keterlambatan parah (di atas 60 menit). Pembatalan menyumbang sekitar 2,6% dari sampel.

E. Analisis Bandara dan Rute

Bandar Udara Internasional Hartsfield-Jackson Atlanta (ATL) merupakan bandara asal tersibuk dalam dataset dengan 7.702 penerbangan, diikuti Dallas/Fort Worth (DFW, 6.468) dan Chicago O'Hare (ORD, 6.045). ATL mempertahankan rata-rata keterlambatan yang relatif rendah sebesar 8,59 menit meskipun volumenya tertinggi, sementara DFW menunjukkan rata-rata keterlambatan yang lebih tinggi sebesar 13,60 menit. Hal ini mengindikasikan adanya perbedaan struktural dalam manajemen ruang udara dan praktik penjadwalan di kedua hub utama tersebut.

Analisis jarak penerbangan versus keterlambatan tidak menunjukkan korelasi positif yang kuat, mengindikasikan bahwa rute jarak pendek tidak secara inheren lebih tepat waktu dibandingkan rute jarak jauh apabila dikontrol terhadap variabel maskapai dan kepadatan hub. Keberangkatan pada akhir pekan rata-rata mengalami keterlambatan 10,90 menit dibandingkan 9,78 menit pada hari kerja, selisih yang moderat namun konsisten.

F. Perbandingan ETL dan ELT

Dari perspektif rekayasa data, kedua pipeline menghasilkan hasil analitis yang setara dengan perbedaan jumlah rekaman dan metrik kualitas yang dapat diabaikan. Perbedaan utama terletak pada trade-off arsitektural berikut:

Tata Kelola Skema: Star schema ETL memastikan integritas dimensional melalui penyelarasan foreign key yang divalidasi pada saat pemuatan. Pendekatan ELT menyimpan tabel flat denormalisasi yang lebih mudah dikueri secara ad hoc, namun memerlukan kedisiplinan yang lebih tinggi untuk menjaga konsistensi antar lapisan transformasi.

Fleksibilitas Transformasi: ELT memungkinkan analis menambahkan atau memodifikasi logika transformasi dengan menjalankan ulang pernyataan CTAS SQL tanpa harus menjalankan ulang seluruh pipeline ekstraksi. Pada ETL, perubahan logika rekayasa fitur atau pembersihan data mengharuskan pemrosesan ulang melalui notebook Colab.

Lokasi Komputasi: Transformasi ETL dibatasi oleh memori GPU sesi Colab (15.360 MiB untuk Tesla T4), yang mencukupi untuk 150.000 baris tetapi memerlukan pemrosesan terpartisi untuk dataset 3 juta baris secara

penuh. ELT mendelegasikan transformasi ke BigQuery yang skalanya otomatis tanpa batasan sesi.

Keterbacaan Logika: Logika transformasi ETL diekspresikan dalam kode Python/pandas yang familiar bagi ilmuwan data. Logika transformasi ELT dalam SQL lebih mudah diakses oleh analis yang mahir SQL dan engineer BI, serta dapat dikontrol versinya menggunakan alat seperti dbt.

V. KESIMPULAN

Makalah ini menyajikan implementasi dan evaluasi komparatif pipeline big data ETL dan ELT untuk analisis keterlambatan penerbangan domestik AS menggunakan data periode 2019 hingga 2023. Kedua pipeline mencapai hasil kualitas data yang identik pada lima dari enam dimensi validasi, dengan keduanya mencapai integritas referensial 99,9%. Temuan analitis utama meliputi tingkat ketepatan waktu sebesar 66,04%, peningkatan keterlambatan yang signifikan dari 1,71 menit pada masa pandemi 2020 menjadi 14,50 menit pada 2023, JetBlue Airways sebagai maskapai dengan keterlambatan terbesar, serta Hartsfield-Jackson Atlanta sebagai hub tersibuk dengan manajemen keterlambatan yang relatif baik.

Pendekatan ETL lebih direkomendasikan ketika tata kelola skema dan konsistensi dimensional menjadi prioritas utama, karena memastikan struktur pada saat pemuatan dan menghasilkan star schema yang bersih dan sesuai untuk pelaporan BI produksi. Pendekatan ELT lebih direkomendasikan untuk analitik eksplorasi dan pengembangan iteratif, karena mempertahankan data mentah di warehouse dan memungkinkan logika transformasi berkembang tanpa eksekusi ulang pipeline. Dalam arsitektur cloud-native di mana komputasi SQL serverless BigQuery tersedia, ELT menawarkan skalabilitas yang lebih baik untuk dataset yang melampaui batasan memori sesi GPU.

Penelitian selanjutnya akan memperluas pipeline ke dataset 3 juta baris penuh menggunakan ingesti native BigQuery, mengintegrasikan prediksi keterlambatan menggunakan gradient boosting yang dilatih pada fitur-fitur yang telah direkayasa, serta mengeksplorasi ekstensi streaming real-time menggunakan Apache Kafka atau Google Pub/Sub untuk pemantauan penerbangan langsung.

REFERENSI

- [1] P. Zelazko, "Flight Delay and Cancellation Dataset (2019–2023)," Kaggle, 2023. [Online]. Tersedia: <https://www.kaggle.com/datasets/patrickzel/flight-delay-and-cancellation-dataset-2019-2023>
- [2] S. Kocharyan, "Global Airports Dataset (IATA, ICAO, Timezone)," Kaggle, 2023. [Online]. Tersedia: <https://www.kaggle.com/datasets/samvelkoch/global-airports-iata-icao-timezone>
- [3] NVIDIA Corporation, "RAPIDS cuDF: GPU DataFrame Library," 2024. [Online]. Tersedia: <https://docs.rapids.ai/api/cudf/stable/>
- [4] R. Kimball dan M. Ross, *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*, Edisi ke-3. Indianapolis: Wiley, 2013.
- [5] R. Kimball, "A Dimensional Modeling Manifesto," *DBMS Magazine*, vol. 10, no. 9, hal. 58–70, 1997.
- [6] T. Bailis, V. Sreeram, dan J. Crites, "Materializing the Web," *Proc. VLDB Endow.*, vol. 12, no. 12, hal. 2195–2198, 2019.
- [7] W. Sievert, J. McCreight, dan A. Patel, "GPU-Accelerated Dataframe Operations for Large-Scale Data Engineering," dalam *Proc. IEEE Big Data*, hal. 1543–1550, 2022.
- [8] Y. Choi, S. Kim, dan J. Park, "Flight Delay Prediction Using Machine Learning: A Survey," *IEEE Access*, vol. 9, hal. 178531–178542, 2021.
- [9] G. Gui, F. Liu, J. Sun, J. Yang, Z. Zhou, dan D. Zhao, "Flight Delay Prediction Based on Aviation Big Data and Machine Learning," *IEEE Trans. Veh. Technol.*, vol. 69, no. 1, hal. 140–150, Jan. 2020.
- [10] Google Cloud, "BigQuery Documentation: Creating and Managing Datasets," 2024. [Online]. Tersedia: <https://cloud.google.com/bigquery/docs>